


CLASSIFICANDO A QUALIDADE DE VINHOS COM ML

Pós Data Analytics



FIAP

Componentes do grupo

Vinicius Lopes Romão – RM372386

Email: vini.romao159@gmail.com

Maycon Suel da Silva Nunes – RM370867

Email: nunes.maycon2005@gmail.com

Carlos Henrique Freitas – RM371149

Email: ch_freitas@hotmail.com

Sumário

1. Sumário Executivo	4
2. Introdução	5
3. Análise Exploratória (EDA).....	5
4. Machine Learning	9
5. Resultados	10
6. Entregáveis	12
6.1. Repositório	12
6.2. Slide	12
6.3. Vídeo	12
6.4. Drive	12
7. Glossário de Termos Técnicos	13
8. Ferramentas e Tecnologias	15
9. Referências	16

1. Sumário Executivo

A avaliação da qualidade do vinho é, tradicionalmente, um processo realizado por especialistas humanos, baseado em análises sensoriais subjetivas. Esse método, embora eficaz, demanda tempo, gera custos elevados e está sujeito à variação de percepção entre avaliadores. Com o avanço das técnicas de ciência de dados, tornou-se possível utilizar características físico-químicas mensuráveis em laboratório para prever a qualidade do vinho de forma objetiva, consistente e escalável.

Este projeto desenvolveu e comparou três modelos de aprendizado de máquina: Regressão Logística, Random Forest e XGBoost que foram capazes de classificar vinhos tintos da região dos Vinhos Verdes portugueses como Alta Qualidade (nota igual ou superior a 7) ou Baixa/Média Qualidade (nota inferior a 7), com base em 11 características físico-químicas como teor alcoólico, acidez volátil e sulfatos.

O modelo Random Forest foi selecionado como o mais adequado para o problema, por apresentar o melhor equilíbrio entre precisão e capacidade de identificação de vinhos de alta qualidade. Em termos práticos, de cada 100 vinhos analisados, o modelo classifica corretamente 91. Dos vinhos apontados como de alta qualidade, 2 em cada 3 realmente o são e de todos os vinhos verdadeiramente excelentes disponíveis, o modelo encontra 7 em cada 10.

A análise revelou que o teor alcoólico e a acidez volátil são os fatores que mais determinam a qualidade final do vinho, resultado consistente tanto na análise exploratória dos dados quanto no aprendizado dos modelos. Isso sugere que o controle rigoroso do processo de fermentação é o principal alavancador de qualidade na produção vinícola.

O modelo não tem como objetivo substituir o julgamento do sommelier. Sua proposta é atuar como uma ferramenta de triagem inteligente, direcionando a atenção do especialista para os lotes com maior potencial de excelência, tornando o processo de certificação mais ágil e economicamente eficiente.

2. Introdução

A história da humanidade é marcada por tradições, descobertas e produtos que atravessaram séculos, e o vinho é um dos exemplos mais emblemáticos. Registros históricos indicam sua presença desde aproximadamente 6000 a.C., desempenhando um papel relevante em aspectos econômicos, socioculturais e religiosos ao longo da evolução das civilizações.

Desde a antiguidade, a degustação tem sido utilizada como principal forma de avaliar a qualidade dos vinhos. Por meio da análise de sabores, aromas e outras características sensoriais, especialistas e consumidores classificavam os produtos e definiam seu valor percebido no mercado.

Entretanto, a percepção de qualidade nem sempre é subjetiva. Alguns vinhos consistentemente se destacam em avaliações, levantando uma questão importante: quais características influenciam a qualidade de um vinho?

Para responder a essa pergunta, realizamos uma análise exploratória do dataset de vinhos tintos da região de Vinho Verde, que reúne informações sobre diferentes compostos químicos presentes no produto, além de sua respectiva avaliação de qualidade.

3. Análise Exploratória (EDA)

A qualidade do vinho é um conceito naturalmente subjetivo, influenciado por fatores como produção, armazenamento, variedade da uva, safra e preferências individuais dos consumidores. Mesmo diante dessa subjetividade, o dataset utilizado adota um sistema padronizado de avaliação, atribuindo notas de qualidade em uma escala de 1 a 10 para cada vinho analisado.




Figura 1 - Distribuição da Qualidade dos Vinhos

Observa-se uma forte concentração de vinhos nas notas intermediárias, especialmente entre 5 e 7 pontos, indicando que a maior parte da amostra é composta por vinhos de qualidade considerada média. Isso indica que temos vinhos de qualidades semelhantes, considerando a ausência de vinhos com notas inferiores a 3 e superiores a 8.

Com base nessas informações, exploramos os componentes químicos presentes no dataset para entender quais deles mais influenciam na qualidade final do vinho. Abaixo, observamos o gráfico de correlação entre as variáveis e seus impactos na qualidade.




Figura 2 - Matriz de correlação entre variáveis




Figura 3 - Força Absoluta do Impacto das Variáveis

Observa-se que algumas variáveis apresentam correlações relevantes, mas duas delas se destacam por sua maior relação com a qualidade dos vinhos: álcool (*alcohol*) e acidez volátil (*volatile acidity*). Os gráficos abaixo apresentam o comportamento dessas variáveis em relação à pontuação dos vinhos.




Figura 4 - Correlação entre qualidade e álcool




Figura 5 - Correlação entre qualidade e acidez volátil

Com base nessas informações e nas variáveis disponíveis no dataset, testamos e implementamos modelos de Machine Learning para prever possíveis vinhos de boa qualidade (nota ≥ 7) e vinhos de menor qualidade (nota < 7), com o objetivo de apoiar um pipeline de controle de qualidade.

4. Machine Learning

Nosso objetivo foi identificar vinhos de alta qualidade por meio das variáveis presentes no dataset, permitindo a classificação de futuros vinhos com base nos padrões observados nos dados históricos.

Devido ao desbalanceamento entre a quantidade de vinhos de alta qualidade e os demais vinhos, testamos modelos capazes de capturar adequadamente a complexidade das variáveis, aprendendo padrões relevantes e minimizando o risco de não identificar vinhos de boa qualidade. Essa abordagem busca evitar perdas de produtos potencialmente valiosos, reduzindo impactos financeiros e riscos à percepção de qualidade da marca.

Utilizamos três modelos de Machine Learning em busca dos melhores resultados: Regressão Logística, Random Forest e XGBoost. Cada modelo recebeu ajustes específicos para lidar com o desequilíbrio da base, incluindo técnicas de balanceamento, calibração do limiar de decisão (*threshold*) e otimização de hiperparâmetros.

A principal métrica utilizada na avaliação dos modelos foi o Recall, que mede a capacidade do modelo de identificar corretamente os casos positivos. Nesse contexto, o Recall indica a proporção de vinhos de alta qualidade que foram corretamente classificados como tal, sendo uma métrica fundamental para minimizar a perda de produtos que atendem aos padrões desejados.

5. Resultados

O Random Forest foi o modelo escolhido para o projeto por apresentar o melhor equilíbrio entre capacidade preditiva e identificação de vinhos de alta qualidade. O algoritmo combina centenas de árvores de decisão treinadas de forma independente e realiza a classificação final por meio de votação majoritária, tornando-o mais robusto e menos suscetível a erros pontuais ou padrões específicos dos dados de treinamento.

Para tornar os números mais concretos, imagine uma linha de produção com 100 vinhos passando pelo modelo:

- De cada 100 vinhos analisados, o modelo identifica corretamente 91, seja para reconhecer vinhos bons ou descartar os medianos. Isso representa a acurácia de 91%.
- Dos vinhos que o modelo aponta como de alta qualidade, 2 em cada 3 realmente são bons. O modelo não é infalível — 1 em cada 3 pode ser um falso alarme. Isso é a Precision de 66%.
- De todos os vinhos verdadeiramente excelentes que existem na produção, o modelo encontra 7 em cada 10. Os outros 3 passam despercebidos. Isso é o Recall de 71%.
- O F1-Score de 68% resume o equilíbrio entre essas duas métricas, sendo a nota geral do modelo considerando tanto os acertos quanto os erros de cada tipo.

É importante destacar que o objetivo do modelo não é substituir o sommelier ou o enólogo, e sim servir como uma ferramenta de triagem que direciona a atenção do especialista. Em vez de avaliar manualmente centenas de amostras, o profissional pode concentrar seu tempo nos lotes que o modelo sinalizou como promissores, tornando o processo de certificação mais ágil e econômico.

A tabela abaixo apresenta a comparação completa entre os três modelos testados:

Modelo	Acurácia	Precision	Recall	F1-Score	AUC
Regressão Logística	0,76	0,35	0,90	0,50	0,90
Random Forest ✓	0,91	0,66	0,71	0,68	0,90
XGBoost	0,85	0,46	0,63	0,53	0,90

A análise da importância das variáveis mostrou que os fatores que mais influenciaram as previsões do modelo foram o teor alcoólico (*alcohol*), a acidez volátil (*volatile acidity*) e a densidade (*density*). Esses resultados reforçam os achados da análise exploratória, indicando que características químicas específicas possuem papel relevante na determinação da qualidade final do vinho.

Entre os três modelos avaliados, os três atingiram AUC de 0,90 indicando capacidade discriminativa equivalente. O que os diferencia é o trade-off entre Precision e Recall: o Random Forest apresentou o melhor equilíbrio geral, enquanto a Regressão Logística, graças ao uso do SMOTE, destacou-se pelo maior Recall (0,90), sendo mais adequada em cenários onde o objetivo é não perder nenhum vinho de alta qualidade. O XGBoost, apesar de ser o algoritmo mais sofisticado dos três, não superou o Random Forest nesta base de dados, acreditamos que isso se deve ao tamanho reduzido da amostra, que não oferece volume suficiente para o algoritmo extrair todo o seu potencial.

6. Entregáveis

6.1. Repositório

Todo o código utilizado nas análises está disponível no repositório GitHub do grupo:

[Repositório do GitHub](#)

6.2. Slide

Os slides da apresentação executiva, pode ser acessado pelo link:

[Apresentação Executiva](#)

6.3. Vídeo

O vídeo da apresentação está disponível no YouTube, pode ser acessado pelo link:

[Vídeo Executivo](#)

6.4. Drive

O drive com os entregáveis do projeto, pode ser acessado pelo link:

[Drive](#)

7. Glossário de Termos Técnicos

Este glossário reúne os principais termos técnicos utilizados ao longo do relatório, com explicações em linguagem acessível.

Acurácia

Percentual geral de acertos do modelo. Indica quantos vinhos foram classificados corretamente, seja como alta qualidade ou baixa/média qualidade. É uma métrica intuitiva, mas pode ser enganosa quando os dados são desbalanceados.

AUC (Area Under the Curve)

Medida que indica a capacidade do modelo de distinguir vinhos bons de ruins, independentemente do limiar de decisão utilizado. Varia de 0,50 (equivale a um chute aleatório) a 1,00 (modelo perfeito). Todos os três modelos do projeto atingiram AUC de 0,90, classificado como excelente.

Desbalanceamento de classes

Situação em que uma categoria tem muito mais amostras do que a outra. Neste projeto, aproximadamente 86% dos vinhos são de baixa/média qualidade e apenas 14% são de alta qualidade. Isso exige técnicas especiais para que o modelo aprenda a identificar corretamente os vinhos bons.

F1-Score

Média harmônica entre Precision e Recall. Penaliza modelos que são bons em apenas uma das duas métricas e resumem o equilíbrio geral do modelo em um único número. É especialmente útil em bases desbalanceadas.

Hiperparâmetros

Configurações do modelo que são definidas antes do treinamento e afetam o seu comportamento como o número de árvores no Random Forest ou a taxa de aprendizado do XGBoost. A otimização de hiperparâmetros busca a combinação que produz os melhores resultados.

Precision (Precisão)

De todos os vinhos que o modelo classificou como alta qualidade, quantos realmente eram? Uma Precision de 66% significa que, a cada 3 vinhos apontados como bons, 2 realmente o são e 1 é um falso alarme.

Random Forest

Algoritmo de Machine Learning que combina centenas de árvores de decisão, cada uma treinada com um subconjunto diferente dos dados. A classificação final é feita por votação majoritária entre todas as árvores, tornando o modelo mais robusto e confiável.

Recall (Sensibilidade)

De todos os vinhos verdadeiramente excelentes existentes, quantos o modelo conseguiu identificar? Um Recall de 71% significa que, de cada 10 vinhos bons, o modelo encontra 7 e perde 3.

Regressão Logística

Modelo de Machine Learning que calcula a probabilidade de um vinho pertencer a cada classe (alta ou baixa qualidade), aprendendo o peso de cada variável química na determinação desse resultado.

SMOTE (Synthetic Minority Over-sampling Technique)

Técnica utilizada para equilibrar bases de dados desbalanceadas, criando amostras sintéticas da classe minoritária, neste caso, vinhos de alta qualidade de forma a auxiliar o modelo a aprender melhor os padrões dessa categoria.

Threshold (Limiar de Decisão)

Ponto de corte que define a partir de qual probabilidade o modelo classifica um vinho como alta qualidade. O padrão é 50%, mas calibrá-lo para 35% — como fizemos neste projeto — permite encontrar mais vinhos bons, ao custo de alguns falsos alarmes a mais.

XGBoost (Extreme Gradient Boosting)

Algoritmo avançado de Machine Learning que cria árvores de decisão de forma sequencial, cada uma corrigindo os erros da anterior. É amplamente utilizado em competições e no mercado por sua alta performance, mas demanda maior volume de dados para atingir seu potencial máximo.

8. Ferramentas e Tecnologias

- Python;
- Git e GitHub;

Plataformas e Ferramentas de Suporte

- Microsoft Word — elaboração do relatório executivo;
- Canva - elaboração da apresentação executiva;
- Windows Movie Maker – Criação e edição do vídeo executivo;

9. Referências

- Revista Boletim do Centro de Pesquisa e Processamento de Alimentos. Análise Sensorial de Vinhos: Conceitos e Aplicações. Disponível em: revistas.ufpr.br/alimentos/article/view/14227. Acesso em: 2026.
- MDPI – Beverages. Machine Learning Approaches for Wine Quality Prediction. Disponível em: mdpi.com/2306-5710/9/2/41. Acesso em: 2026.
- MDPI – Foods. Wine Quality Assessment and Chemical Characteristics Analysis. Disponível em: mdpi.com/2304-8158/10/6/1424. Acesso em: 2026.
- MDPI – Molecules. Chemical Composition and Quality Attributes of Wines. Disponível em: mdpi.com/1420-3049/26/3/718. Acesso em: 2026.
- Kaggle. Wine Quality Dataset. Disponível em: kaggle.com/datasets/yasserh/wine-quality-dataset. Acesso em: 2026.
- Carnegie Mellon University. The Strongest Predictors of Wine Quality. Capstone Research, Fall 2024. Disponível em: stat.cmu.edu/capstoneresearch/fall2024/315files_f24/team8.html.